

Derivate Parțiale și Gradientul

Gradientul funcției de cost este un vector de derivate parțiale care indică direcția de creștere maximă a funcției. Dacă $J(\theta)$ este o funcție de mai multe variabile (parametri), gradientul este dat de:

$$\nabla J(\theta) = \left[\frac{\partial J(\theta)}{\partial \theta_1}, \frac{\partial J(\theta)}{\partial \theta_2}, \dots, \frac{\partial J(\theta)}{\partial \theta_n} \right]$$

Algoritmul Gradient Descent

Algoritmul Gradient Descent începe cu o estimare inițială a parametrilor θ și iterativ își actualizează valorile pentru a reduce funcția de cost. Actualizarea parametrilor se face conform următoarei reguli:

$$\theta := \theta - \alpha \nabla J(\theta)$$

unde:

- α este rata de învățare, un parametru scalar care controlează pasul actualizării.
- $\nabla J(\theta)$ este gradientul funcției de cost.

Pași Detaliați

1. Inițializarea Parametrilor:

- Alege o valoare inițială pentru θ .

2. Calcularea Gradientului:

- Calculează gradientul funcției de cost în punctul curent θ :

$$\nabla J(\theta) = \left[\frac{\partial J(\theta)}{\partial \theta_1}, \frac{\partial J(\theta)}{\partial \theta_2}, \dots, \frac{\partial J(\theta)}{\partial \theta_n} \right]$$

3. Actualizarea Parametrilor:

- Actualizează parametrii utilizând regula:

$$\theta := \theta - \alpha \nabla J(\theta)$$

4. Convergență:

- Repetă pașii 2 și 3 până când gradientul este suficient de mic sau până când schimbările în θ sunt neglijabile.

Exemplu de Regresie Liniară

Pentru a face lucrurile mai concrete, să luăm un exemplu simplu de regresie liniară cu o funcție de cost de formă:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

unde:

- $h_{\theta}(x) = \theta_0 + \theta_1 x$ este funcția ipotezei (predicția modelului).
- m este numărul de exemple de antrenament.
- $x^{(i)}$ și $y^{(i)}$ sunt valorile caracteristicii și respectiv, eticheta pentru exemplul i .

Gradientul pentru fiecare parametru θ_j este:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Algoritmul Gradient Descent pentru acest caz devine:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Explicarea Detaliată a Matematicii din Spatele Gradient Descent

3. Calculul Gradientului:

- "Gradientul funcției de cost $\nabla J(\theta)$ este un vector de derivate parțiale în raport cu fiecare parametru θ_j . Acest gradient indică direcția de creștere maximă a funcției de cost."

- "Matematic, gradientul pentru $J(\theta)$ este dat de:

$$\nabla J(\theta) = \left[\frac{\partial J(\theta)}{\partial \theta_1}, \frac{\partial J(\theta)}{\partial \theta_2}, \dots, \frac{\partial J(\theta)}{\partial \theta_n} \right]$$

4. Actualizarea Parametrilor:

- "Parametrii θ sunt actualizați iterativ folosind regula:

$$\theta := \theta - \alpha \nabla J(\theta)$$

- unde α este rata de învățare care controlează mărimea pașilor de actualizare."

5. Regresia Liniară:

- "În contextul regresiei liniare, funcția de cost $J(\theta)$ este adesea definită ca eroarea pătratică medie (MSE). Gradientul pentru θ în acest caz este calculat ca:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)**}$$

- "Aplicând Gradient Descent, parametrii sunt actualizați conform formulei:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)**}$$

Exemplu concret

Să luăm un exemplu simplu cu un model liniar $h_{\theta}(x) = \theta_0 + \theta_1 x$ și să vedem cum se aplică Gradient Descent:

1. Funcția de cost:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)})^2$$

2. Gradientul:

$$\begin{aligned} \frac{\partial J(\theta)}{\partial \theta_0} &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) \\ \frac{\partial J(\theta)}{\partial \theta_1} &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) x^{(i)} \end{aligned}$$

3. Actualizarea parametrilor:

$$\begin{aligned} \theta_0 &:= \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) \\ \theta_1 &:= \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) x^{(i)} \end{aligned}$$

Implementare pas cu pas

1. Inițializează parametrii: θ_0 și θ_1 la valori inițiale, de exemplu 0.

2. Setează rata de învățare: α (de exemplu, 0.01).

3. Repetă până la convergență:

- Calculează predicțiile: $h_{\theta}(x) = \theta_0 + \theta_1 x$

- Calculează gradientul:

$$\begin{aligned} \text{grad}_{\theta_0} &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) \\ \text{grad}_{\theta_1} &= \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) x^{(i)} \end{aligned}$$

- Actualizează parametrii:

$$\begin{aligned} \theta_0 &:= \theta_0 - \alpha \cdot \text{grad}_{\theta_0} \\ \theta_1 &:= \theta_1 - \alpha \cdot \text{grad}_{\theta_1} \end{aligned}$$