

## Derivate Parțiale și Gradientul

Gradientul funcției de cost este un vector de derivate parțiale care indică direcția de creștere maximă a funcției. Dacă  $J(\theta)$  este o funcție de mai multe variabile (parametri), gradientul este dat de:

$$\nabla J(\theta) = \left[ \frac{\partial J(\theta)}{\partial \theta_1}, \frac{\partial J(\theta)}{\partial \theta_2}, \dots, \frac{\partial J(\theta)}{\partial \theta_n} \right]$$

## Algoritmul Gradient Descent

Algoritmul Gradient Descent începe cu o estimare inițială a parametrilor  $\theta$  și iterativ își actualizează valorile pentru a reduce funcția de cost. Actualizarea parametrilor se face conform următoarei reguli:

$$\theta := \theta - \alpha \nabla J(\theta)$$

unde:

- $\alpha$  este rata de învățare, un parametru scalar care controlează pasul actualizării.
- $\nabla J(\theta)$  este gradientul funcției de cost.

## Pași Detaliați

### 1. Inițializarea Parametrilor:

- Alege o valoare inițială pentru  $\theta$ .

### 2. Calcularea Gradientului:

- Calculează gradientul funcției de cost în punctul curent  $\theta$ :

$$\nabla J(\theta) = \left[ \frac{\partial J(\theta)}{\partial \theta_1}, \frac{\partial J(\theta)}{\partial \theta_2}, \dots, \frac{\partial J(\theta)}{\partial \theta_n} \right]$$

### 3. Actualizarea Parametrilor:

- Actualizează parametrii utilizând regula:

$$\theta := \theta - \alpha \nabla J(\theta)$$

### 4. Convergență:

- Repetă pașii 2 și 3 până când gradientul este suficient de mic sau până când schimbările în  $\theta$  sunt neglijabile.

## Exemplu de Regresie Liniară

Pentru a face lucrurile mai concrete, să luăm un exemplu simplu de regresie liniară cu o funcție de cost de formă:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

unde:

- $h_{\theta}(x) = \theta_0 + \theta_1 x$  este funcția ipotezei (predicția modelului).
- $m$  este numărul de exemple de antrenament.
- $x^{(i)}$  și  $y^{(i)}$  sunt valorile caracteristicii și respectiv, eticheta pentru exemplul  $i$ .

Gradientul pentru fiecare parametru  $\theta_j$  este:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Algoritmul Gradient Descent pentru acest caz devine:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$